A quién cobrar primero: score de pago tardío para la cartera de un grupo de servicios

> **Proyecto Final Integrador · Machine Learning I · Universidad EAN** · Equipo **ArbolesDeIndecision**
> **Claudia Naranjo** (Jefa) · **Yery Pedraza** (Líder) · **Nicolás Ruiz** (Crack) · Octubre de 2026
> Enfoque: **intraemprendimiento** · Repositorio: `github.com/yepedraza/priorizacion-cobro-cartera` · Los datos de la compañía no están en el repositorio.

Cada cifra sale de un artefacto del repositorio, citado entre corchetes: R10 a R18 en `retos/`, y la evaluación final (`evaluacion_B.ipynb`) y el componente C (`plazo_C.ipynb`) en `entrega/`. Los montos de la base están escalados por la compañía, así que los totales en pesos son aproximados; los porcentajes son exactos.

1. Problema y decisión

El problema es la velocidad de cobro, no la cartera incobrable. La compañía es un grupo colombiano de servicios (cuatro empresas, once unidades de negocio) que vende a crédito, sobre todo a empresas. El 96 % de sus saldos termina en cero, pero el dinero llega **unos 22 días después de lo pactado**: 43 días reales frente a 21 pactados, ponderados por monto [R10, viabilidad §2 y §5]. Cada día de recaudo equivale a lo que se factura en un día, del orden de **$65 M** (aproximado, por el escalado de montos).

La decisión que se apoya. Dos gestoras de cartera, supervisadas por un controller, eligen cada día a qué clientes dar seguimiento personal. Alcanzan unos **20 clientes por día**, de unos **135 con facturas vencidas** en un día típico de 2025 [R10, viabilidad §6]. Hoy los eligen en un tablero por saldo más alto y vencimiento más próximo: la factura que está por cumplir 30 días de mora. Esa regla mira lo que ya se atrasó.

Pregunta	Respuesta
¿Qué se decide?	A qué 20 clientes dedicar el seguimiento humano cada día hábil
¿Quién decide?	Las gestoras; el controller supervisa. El modelo ordena, no decide
¿A quién afecta?	Clientes (presión de cobro), gestoras (su tiempo) y tesorería (cuándo entra el dinero)
Métrica de negocio	Del dinero aún en duda que terminó pagándose con más de 30 días de atraso, qué parte estaba en la lista de 20, frente a la regla actual (backtest, §5)
Métrica técnica	AUC-PR, con calibración de la probabilidad

Ruta de intraemprendimiento. El proyecto es una mejora para el área de cartera de la propia compañía, declarada desde el anteproyecto (R10).

Elemento	En este proyecto
Organización y usuarios	El área de cartera del grupo: las dos gestoras, que usan la lista cada mañana, y el controller, que supervisa. Tesorería recibe el efecto
Propuesta de valor	Una lista diaria que dice a qué 20 clientes contactar primero, ordenada por **probabilidad de pago tardío × saldo**, para cobrar antes con la misma capacidad y sin contratar personal
Hipótesis de mejora	Con el mismo cupo de 20 clientes, la lista concentra más dinero en riesgo que la regla actual y, si se gestiona ese dinero antes, se acorta el recaudo
Estimación de impacto	Cada día menos de recaudo libera en caja lo que se factura en un día, ≈ $65 M [R10, viabilidad §2]. **Supuestos declarados:** la cifra es aproximada, porque los montos están escalados; supone que el efecto se sostiene en toda la cartera; y **no se ha medido cuántos días acorta la lista**. El backtest solo muestra que la lista contiene más dinero en riesgo (47,4 % frente a 37,9 %, §5). Por eso el impacto se expresa por día de recaudo ganado, no como un ahorro prometido
Ruta de validación	Primero, el backtest sobre un periodo no visto (§5), ya hecho. Después, un piloto con clientes asignados al azar a la gestión nueva o a la actual, que mide los días hasta el pago (§6)

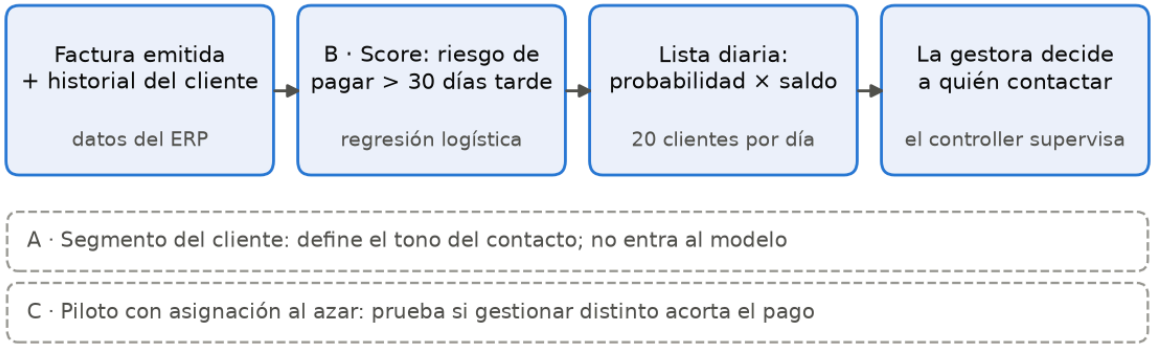


Figura 1. Cómo se usa el modelo en la operación. B ordena la lista; la gestora decide. A y C son complementos.

La solución tiene tres componentes. **B**, el score de pago tardío, es el modelo supervisado que alimenta la lista. **A** agrupa a los clientes por cómo pagan y define el tono del contacto; no entra como variable de B, porque se calcula con la misma información que la etiqueta. **C** estima cuánto tarda de verdad cada segmento en pagar y diseña el piloto. Se descartaron, entre otros, evaluar el desempeño por vendedor (riesgo ético de juzgar a trabajadores con datos no diseñados para eso) y la proyección de recaudo (no cambia a quién se cobra) [R10 §4].

2. Datos

Procedencia. Sistema contable (ERP) de la compañía: 19.262 saldos (54 columnas) y 40.519 movimientos (44 columnas), de diciembre de 2019 a octubre de 2026, con 648 clientes. La compañía autorizó su uso por escrito para este proyecto y los anonimizó de forma irreversible: nombres y códigos reemplazados, montos multiplicados por un factor secreto por saldo y una columna de actividad inventada. Fecha de corte y de acceso: 18/10/2026. No hay licencia pública; los datos no se redistribuyen y quedan en `datos_crudos/`, excluida de Git [R11, ficha §1 y §2].

El objetivo se construye. La base no dice si una factura se pagó tarde. Se define `tardía` = 1 si la factura se pagó **más de 30 días después de vencer**, midiendo el atraso **hasta el último recibo de caja**, no hasta que el saldo queda en cero. La diferencia importa: 1.795 facturas

llegaron a cero con una nota o un ajuste contable, no con dinero. Medir hasta el cero mezclaba «cliente que paga tarde» con «contabilidad que cierra tarde» [R11, diagnóstico §1].

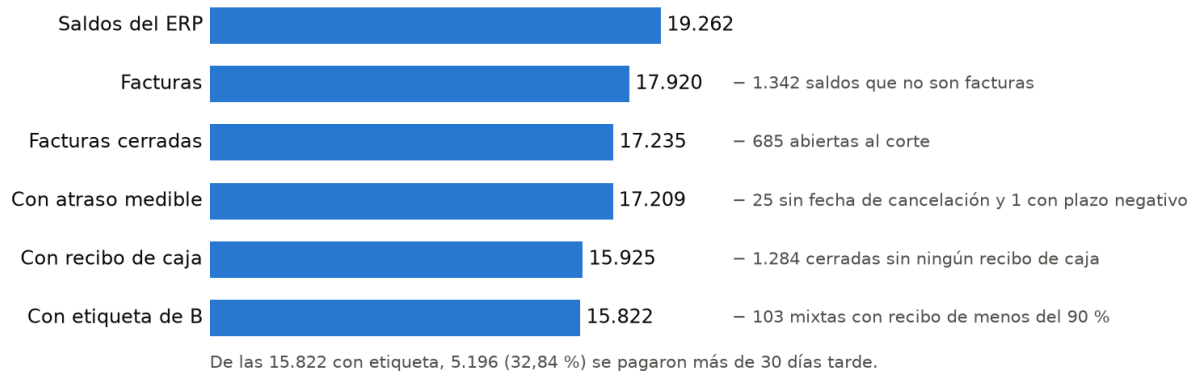


Figura 2. De los saldos del ERP a las facturas con etiqueta. Las 685 abiertas al corte salen por diferencia entre 17.920 y 17.235.

Alternativas descartadas para la etiqueta. Usar solo las facturas cerradas con recibo de caja descartaba 511 facturas mixtas, en las que el cliente pagó casi todo (mediana del 99,62 %) y se sabe cuándo; dejarlas todas y solo declararlo dejaba etiquetas falsas dentro. Se eligió medir las mixtas hasta el último recibo y sacar las 1.284 cerradas sin ningún recibo. Las 103 mixtas cuyo recibo cubre menos del 90 % también salen: el 90 % es un criterio del equipo, y con 80 % o 95 % la proporción de tardías queda en 32,86 % y 32,84 % [R11, diagnóstico §1.5 y §1.6].

Calidad. No hay duplicados ni variantes de escritura en las categorías. Los faltantes están solo en columnas posteriores a la emisión, que no entran al modelo; la peor, `dias_mora_actual` (96 %), falta justo cuando el saldo está en cero. Se excluyen 245 saldos con vencimiento anterior a la emisión, un error de registro [R11, ficha §4].

Representatividad y sesgo. El 98,3 % de los saldos es de personas jurídicas nacionales y la **Empresa A concentra el 89 %**. Los resultados no representan bien a personas naturales, clientes del exterior ni a las empresas B, C y D, y así se mide en §6 [R11, ficha §5]. **Límite que no se puede corregir:** según el diccionario de datos, `fecha_vencimiento` refleja su valor al extraer, no necesariamente el original. Si hubo prórrogas, el plazo aparece más largo y el atraso más corto, y eso tocaría la etiqueta, el historial del cliente y el componente C. La base no guarda la fecha original, así que no se puede contar cuántas veces pasó.

3. Preparación y diseño experimental

Partición temporal antes de transformar. El modelo se usa hacia adelante: con lo que se sabe hoy, se ordenan las facturas de mañana. Por eso la partición es por fecha de emisión, con corte el **1/07/2025**, y se agrupa por **trimestre**, no por cliente. Agrupar por cliente habría simulado clientes nuevos, cuando la lista se usa con los mismos clientes, que se repiten mes a mes, y su información principal es su propio historial [R12 §1].

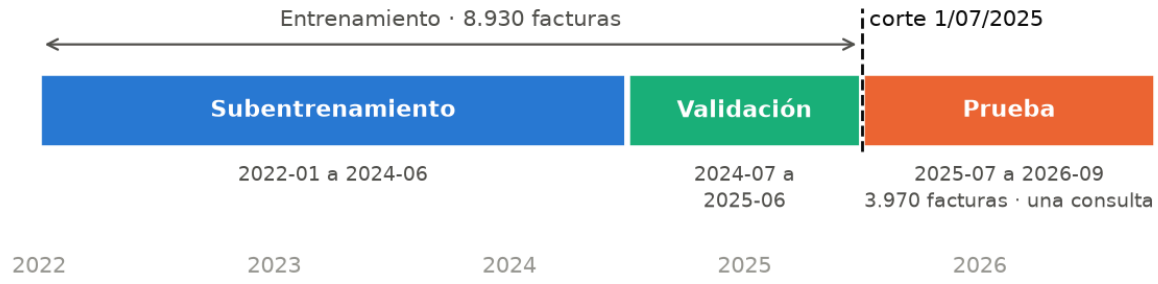


Figura 3. Partición temporal. En cada corte solo entran facturas cuyo desenlace ya se conocía.

Solo lo que se sabe al emitir. Una factura entra a un conjunto solo si ya tuvo 30 días para resolverse después de vencer, para no dejar en la prueba únicamente facturas pagadas a tiempo. Las **11 predictoras** se conocen al emitir la factura: plazo, monto inicial, mes, unidad de negocio y tipo de cliente; y, del historial del cliente **antes** de la emisión, atraso promedio, facturas pagadas, saldo abierto, facturas abiertas y vencidas, y antigüedad. Una prueba automática recalcula el historial fila por fila y da lo mismo en los 1.800 valores revisados [R12 §2].

Columnas excluidas	Motivo
Fecha y tipo de cancelación, créditos, saldo y estado al corte, días de mora	Se conocen después de emitir: serían fuga. `dias_hasta_cancelacion` menos el plazo da exactamente el atraso en el 100 % de las cerradas
«% de facturas con más de 30 días» y el segmento de A	Son la etiqueta resumida por cliente
`total_debitos`, `codigo_cuenta`	Pueden cambiar después de la emisión
`nombre_vendedor`, `empresa`	Uso descartado: el vendedor evaluaría a personas; el grupo se trata como una sola empresa. Se usan solo para auditar
Identificadores de cliente	Para que el modelo no memorice al cliente

Todo dentro de un `Pipeline`. Imputación, escala y codificación se ajustan solo con el entrenamiento de cada pliegue. El **desbalance** (≈ 30 % de tardías) se trata en la comparación con pesos de clase «balanceados», aplicados solo al entrenar [R14 §5]. La semilla es 2026 y las versiones están en `requirements.txt`.

La prueba se consultó una sola vez, el 21/10/2026 a las 22:09, con el modelo, la lista y la métrica ya fijados; nada se cambió después [evaluación B §3]. Las decisiones de modelado se tomaron con validación cruzada dentro del entrenamiento: 5 pliegues de **ventana creciente** por trimestre (2024-T2 a 2025-T2), en los que siempre se entrena con el pasado y se valida con el trimestre siguiente. No se usa una CV estratificada al azar porque mezclaría facturas del futuro en el entrenamiento.

4. Modelado

Línea base y candidatos. La línea base es un clasificador que predice siempre la proporción de tardías. Se compararon seis familias bajo el mismo diseño: un árbol de decisión, regresión logística, SVM con núcleo RBF, bosque aleatorio, gradient boosting y una red neuronal. Los dos ensambles se ajustaron con 30 combinaciones de hiperparámetros cada uno, sobre todas las filas de entrenamiento: la búsqueda los mejoró (0,697 → 0,719 y 0,700 → 0,720), pero dentro de la desviación [R13 §2].

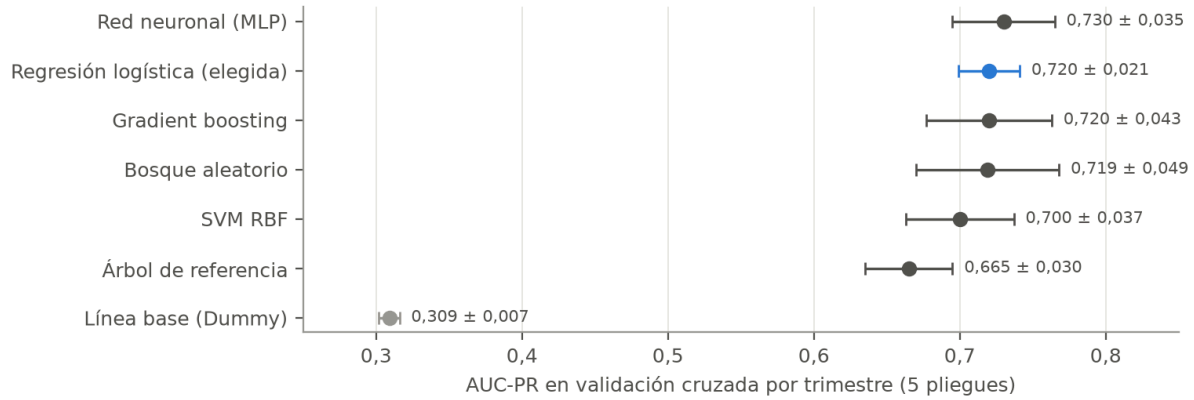


Figura 4. AUC-PR en validación cruzada por trimestre: media ± desviación entre los 5 pliegues.

Regla de elección, fijada antes de ver resultados. Un modelo más complejo reemplaza a la regresión logística solo si su mejora supera la variación de la validación. Ninguno lo logró. La red neuronal tuvo la mejor media (0,730 frente a 0,720) y ganó en 4 de 5 pliegues, y su mejora superó la variación entre semillas (0,002), pero **no la variación entre pliegues (0,035)**: según el trimestre que se valide, la AUC-PR de un mismo modelo cambia casi cuatro veces más que la ventaja de la red. Además, la red entrena unas 30 veces más lento, depende de la semilla y es más difícil de explicar a cartera [R14 §6]. **El modelo final es la regresión logística.**

Sesgo y varianza. La red mostró el lado de la varianza: con dos capas (64 y 32 neuronas) la AUC-PR bajó a 0,696 y se volvió más inestable; con 200 épocas dio menos que con 50. Más capacidad llevaba a memorizar, y la mejor configuración fue la más regularizada (α = 1) [R14 §5]. El árbol de referencia, de 6 niveles y 36 hojas, quedó a 0,011 de su desempeño en el subentrenamiento: no sobreajusta, pero se queda corto frente a los modelos lineales y los ensambles [R12 §4].

Qué usa el modelo. Por permutación en datos no vistos, lo que pesa es el historial del cliente: el atraso promedio (caída de 0,236 en AUC-PR al desordenarlo), las facturas vencidas (0,108) y las facturas pagadas (0,066). Una columna de ruido de control da cero, como debe; la importancia por impureza de un bosque la pone 6.ª, lo que muestra el sesgo de esa medida [R13 §4]. Ninguna importancia indica causa.

Componentes A y C. La segmentación de clientes (A) usa K-means con k = 2 sobre siete variables del perfil de pago hasta junio de 2025, con 158 clientes de entrenamiento. DBSCAN no encontró dos grupos densos con ningún parámetro, y el agrupamiento jerárquico de Ward se reproduce peor [R16, R17]. Quedan dos segmentos: «paga a tiempo o casi» y «paga tarde». Es la segmentación que mejor se reproduce con otra muestra (índice de Rand ajustado mediano de 0,652, frente a 0,385 con k = 3), y anticipa el comportamiento posterior: en los clientes de prueba, «paga tarde» se atrasa en el 80,2 % de sus facturas posteriores y el otro segmento en el 34,3 % (diferencia de 45,9 puntos; p = 0,0006 por permutación de clientes, con solo 10 clientes en «paga tarde») [R17 §2]. C muestra que, con el mismo plazo pactado de 15 días, un segmento paga en una mediana de 28 días y el otro en 72,5, y que dentro del mismo cliente el plazo mueve poco el pago (0,29 días por día de plazo; IC 95 %: 0,07 a 0,61) [C §2 y §3].

5. Evaluación

Por qué AUC-PR. Con un cupo fijo, lo que importa es poner arriba las facturas que se van a atrasar. El error que más cuesta es dejar fuera de la lista dinero que se va a atrasar (falso

negativo); llamar a quien igual iba a pagar (falso positivo) cuesta una llamada. La exactitud se inflaría con el 70 % de facturas a tiempo; la AUC-PR mide el orden en la clase que importa.

Calibración antes de la prueba. La probabilidad se multiplica por el saldo, así que tiene que estar calibrada. Con pesos balanceados la logística sobrestimaba todas las probabilidades. Calibrarla con el método *sigmoid*, como estaba previsto, calibraba mal y bajaba la AUC-PR en validación. Se eligió la misma logística sin pesos de clase, que por cómo se ajusta da probabilidades calibradas: en validación, AUC-PR de 0,723 frente a 0,724 y Brier de 0,145 frente a 0,152 [evaluación B §1].

Resultado técnico en la prueba. En las 3.970 facturas de prueba (julio de 2025 a septiembre de 2026), la **AUC-PR es 0,744 (IC 95 % por bootstrap: 0,721 a 0,768)**, frente a 0,386 de la línea base, y la AUC-ROC es 0,829 [evaluación B §3]. El orden se sostiene en un periodo que el modelo no vio. La cifra no se compara directamente con la validación cruzada: la AUC-PR depende de la proporción de tardías, y por eso la línea base también sube, de 0,309 a 0,386.

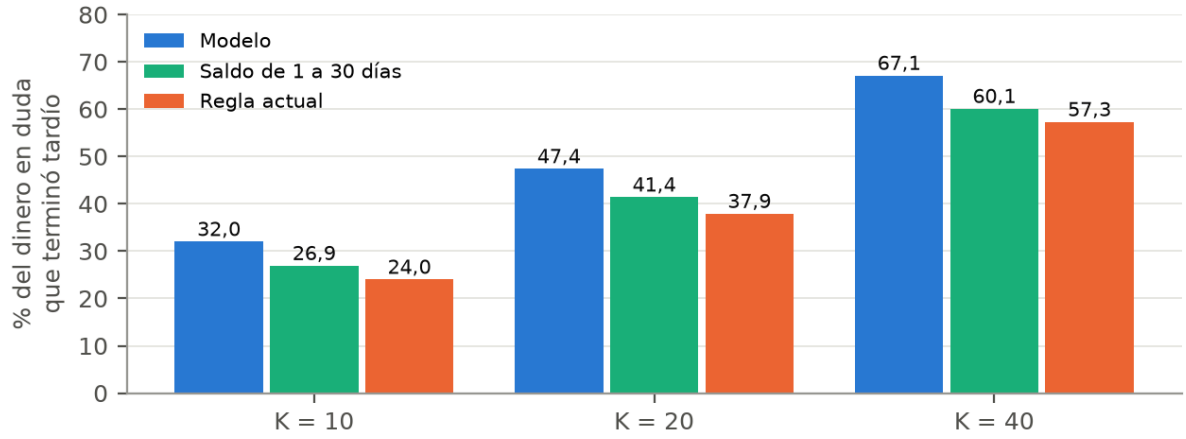


Figura 5. Backtest en los 296 días hábiles de la prueba: % del dinero en duda que terminó tardío y estaba en cada lista.

Resultado de negocio: el backtest. Cada día hábil del 1/07/2025 al 18/08/2026 se reconstruyó la cartera con los movimientos anteriores a ese día y se armaron tres listas: la regla actual, una segunda línea base (saldo vencido en facturas de 1 a 30 días de mora) y la del modelo. Con **K = 20, el modelo captura el 47,4 %** del dinero en duda que terminó tardío, frente al **37,9 % de la regla actual** y al 41,4 % de la segunda línea base. Le gana a la regla actual en **254 de 296 días** y a la segunda línea base en 200; la mediana diaria es 45,8 % frente a 38,0 % y 42,4 %. Con K = 10 y K = 40 el orden es el mismo [evaluación B §3].

Tabla complementaria, siempre secundaria. Contando todo el dinero tardío, también el que ya estaba decidido, la regla actual capta más (46,5 % frente a 43,7 %), porque el 44,7 % del saldo de su lista ya era dinero tardío. Es lo esperado: la regla mira lo que ya se atrasó y el modelo anticipa lo que se va a atrasar. Por eso la métrica principal solo cuenta el dinero todavía en duda.

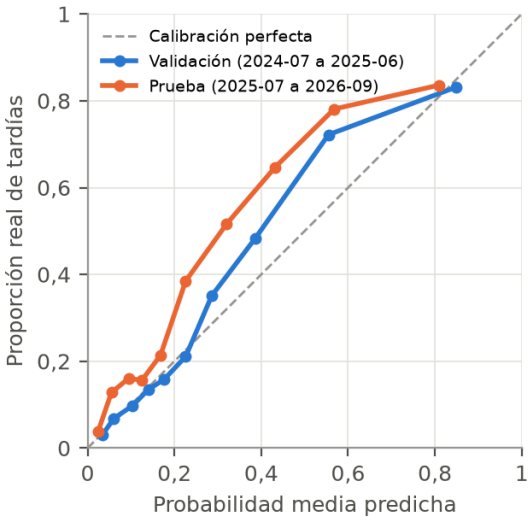


Figura 6. Calibración por decil. En la prueba, el modelo subestima: donde predice 32 %, se atrasa el 52 %.

La probabilidad queda corta en la prueba. En la prueba hay más tardías (38,6 %) que en el entrenamiento (≈ 30 %), y la calibración se desplaza: el orden sigue siendo bueno, pero la probabilidad no se puede leer al pie de la letra [evaluación B §3].

Umbral recomendado. El umbral no es un corte de probabilidad sino el **cupo operativo de 20 clientes por día**, que es la capacidad real de las gestoras. Como el orden se sostiene aunque la probabilidad se desplace, la lista sigue siendo útil con el cupo; un corte fijo de probabilidad, en cambio, marcaría muchas menos facturas de las debidas en un periodo con más tardías.

6. Decisión, límites y gobernanza

Recomendación: adoptar la lista con condiciones. Usarla para ordenar el trabajo de las gestoras, no para prometer ahorros. Reentrenar ya con la historia reciente, porque la proporción de tardías salió del rango de referencia. Vigilar cuatro métricas. Y validar el beneficio con un piloto antes de reportar un efecto.

Lo que se midió y lo que no. El backtest compara qué dinero estaba en cada lista; **no mide si llamar a esos clientes acorta el atraso**. Que el modelo ordene mejor es una correlación medida; que gestionar según la lista cobre antes es una hipótesis causal. Para probarla, C diseña un piloto en el que los clientes activos de cada segmento se asignan **al azar** a una gestión nueva o a la actual. Con todos los clientes activos, el piloto solo detectaría diferencias de 13 a 14 días en «paga a tiempo o casi» y de 25 a 27 en «paga tarde» [C §5]. Tampoco hay una decisión secuencial que justifique un agente de aprendizaje por refuerzo: los datos no registran qué gestión se hizo a cada cliente, así que no hay recompensa por acción que observar [R18 §4].

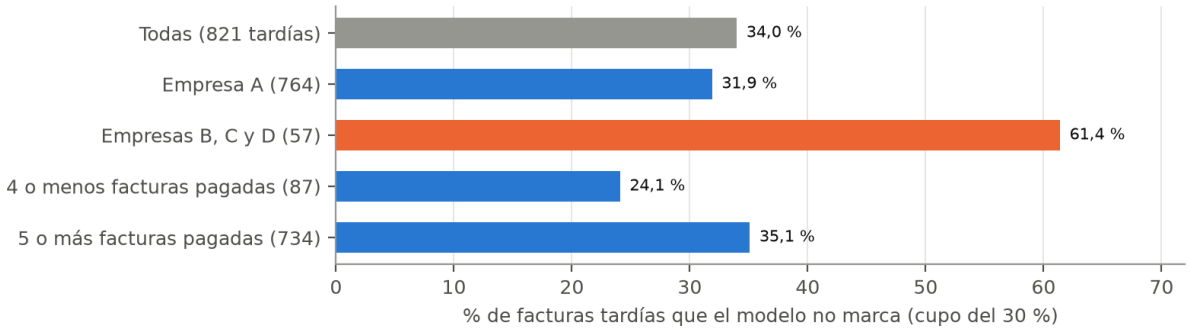


Figura 7. Falsos negativos por grupo con un cupo del 30 % de las facturas de validación. Logística de R13 y R14 (con pesos de clase).

A quién podría perjudicar. El modelo deja pasar el **61,4 % de las facturas tardías de las empresas B, C y D**, frente al 31,9 % de la Empresa A: aprende sobre todo de la A, que tiene el 89 % de los datos, y tratar el grupo como una sola empresa no lo corrige. Su cartera tardía recibiría menos seguimiento. La cifra se apoya en solo 57 facturas tardías y viene de la validación, no de la prueba [R14 §7]. En el otro sentido, el modelo marca el 52,3 % de las facturas de clientes con poca historia, aunque solo el 31 % es tardía: podrían recibir un cobro más insistente sin merecerlo [R13 §5].

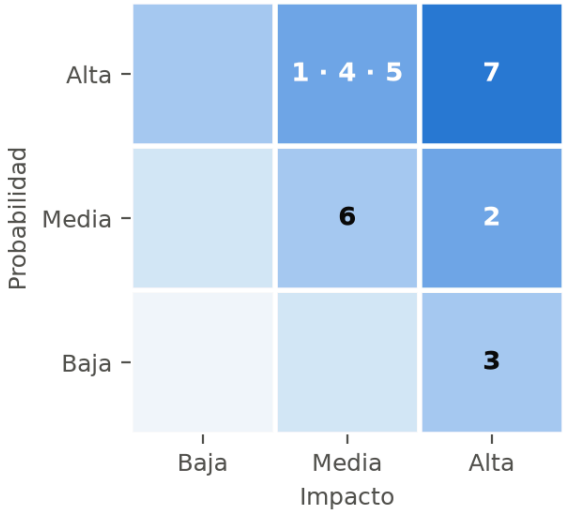


Figura 8. Mapa de riesgos: número de cada riesgo según probabilidad e impacto (juicio del equipo).

#	Riesgo	Mitigación
1	Deriva del nivel de atraso: la probabilidad queda corta	Usar solo el orden; reentrenar con la historia reciente
2	`fecha_vencimiento` puede no ser la original	Preguntar a cartera si prorroga y si guarda la original; si no, declararlo
3	Fuga de datos confidenciales	Datos fuera de Git; aplicación privada, solo durante la sustentación
4	Peor cobertura en las empresas B, C y D	Reportar por empresa; no generalizar; revisar un cupo por empresa
5	Cobro insistente a clientes con poca historia	La gestora decide; quedan sin segmento
6	Profecía autocumplida: los no priorizados se deterioran	Correo semanal para todos; vigilar a los no priorizados
7	Beneficio no demostrado	No prometer ahorros; piloto al azar antes de reportar efecto

Plan de seguimiento [R18 §3]. Los umbrales son un criterio del equipo, no salen de los datos.

Métrica	Referencia	Umbral	Frecuencia
Proporción de facturas tardías	31–34 % anual; 38,6 % en la prueba	Fuera del rango un trimestre: revisar	Mensual
Monto capturado con K = 20 frente a la regla actual	47,4 % frente a 37,9 %	Ventaja < 5 puntos: reentrenar; ≤ 0 dos trimestres: retirar	Trimestral
AUC-PR en facturas nuevas	0,744 (0,721 a 0,768)	Por debajo de 0,721: reentrenar	Trimestral
Falsos negativos B, C y D frente a A	61 % frente a 32 %	Brecha mayor que 29 puntos: revisar el cupo	Trimestral

Condiciones que invalidarían la recomendación: que el modelo deje de superar a la regla actual dos trimestres seguidos, o que el piloto muestre que gestionar distinto no cambia el pago. Como una factura solo tiene desenlace 30 días después de vencer, un deterioro se detecta con al menos un mes de retraso. **La primera métrica ya está fuera del rango**, así que según este plan el modelo debe reentrenarse antes de usarse.

7. Roles y trabajo en equipo

Los tres trabajamos cada fase juntos, sin repartir el proyecto por perfil. Cada decisión quedó registrada con quién la tomó, cómo, qué alternativas se descartaron y quién la defiende.

Integrante y rol	Qué aportó y qué decisiones defiende
Claudia Naranjo, Jefa	La definición del objetivo: atraso hasta el último recibo de caja, desenlace conocido y mixtas con poco recibo. La partición por bloques de tiempo, la segunda línea base y la métrica del backtest. El número de segmentos de A
Yery Pedraza, Líder	La poda del árbol de referencia, la calibración sin pesos de clase, el diseño y la adopción con condiciones de la segmentación, el replanteamiento de C y su piloto, y la decisión de que no hay un problema secuencial
Nicolás Ruiz, Crack	El corte de la partición y las 11 predictoras, el tratamiento del grupo como una sola empresa, la búsqueda de hiperparámetros, el diseño de la comparación de modelos y de la red, y el diseño de la calibración y del backtest con una sola consulta a la prueba

Por consenso de los tres se decidieron el enfoque de intraemprendimiento y los gráficos de este informe. Las demás las tomó cada rol dentro de su ámbito.

Anexos y referencias

Los anexos completos son los archivos `.md` del zip: `ficha_datos.md` (ficha de datos), `declaracion_IA.md` (uso de IA), `anexo_A_enfoque.md` (enfoque) y `anexo_B_datos_reales.md` (datos reales).

Gráficos de validación. Se calcularon con `scripts/figuras_anexo.py` sobre los datos de la compañía, **sin la prueba**: solo facturas emitidas antes del 1/07/2025 y desenlaces conocidos a esa fecha. Las cifras de control coinciden con los cuadernos (AUC-PR de 0,723 en validación; 57,1 %, 50,4 % y 44,3 % en el ensayo del backtest; medianas de 28 y 72,5 días).

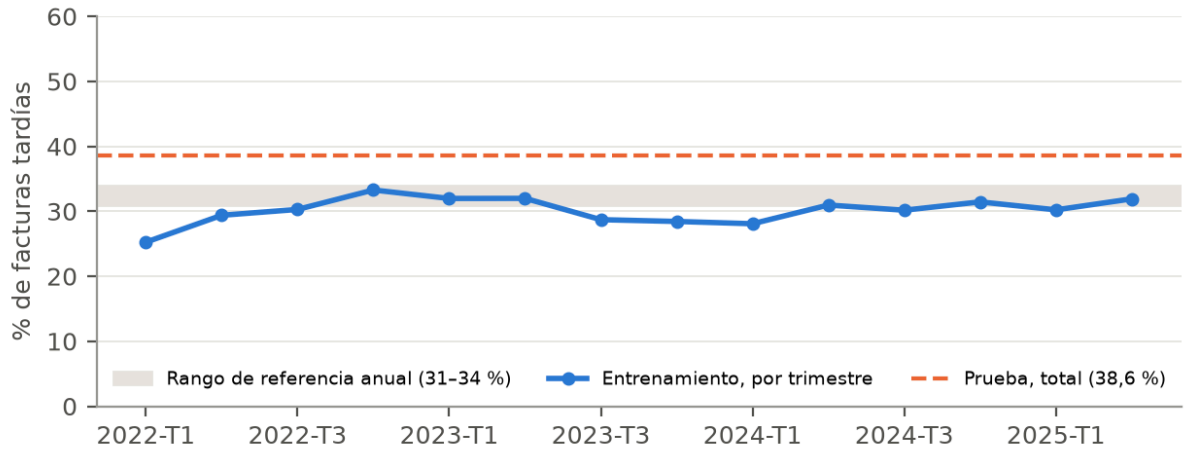


Figura A1. Proporción de tardías por trimestre de emisión en el entrenamiento. La línea naranja es el total de la prueba ya reportado, no un cálculo nuevo.

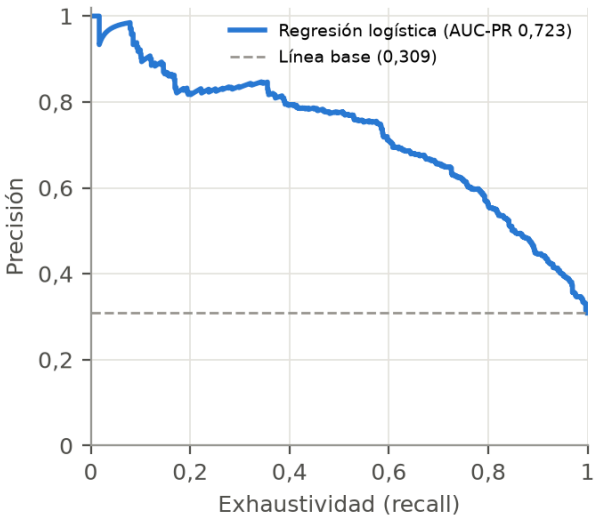


Figura A2. Curva de precisión y exhaustividad en la validación (2024-07 a 2025-06): modelo de la lista entrenado con el subentrenamiento.

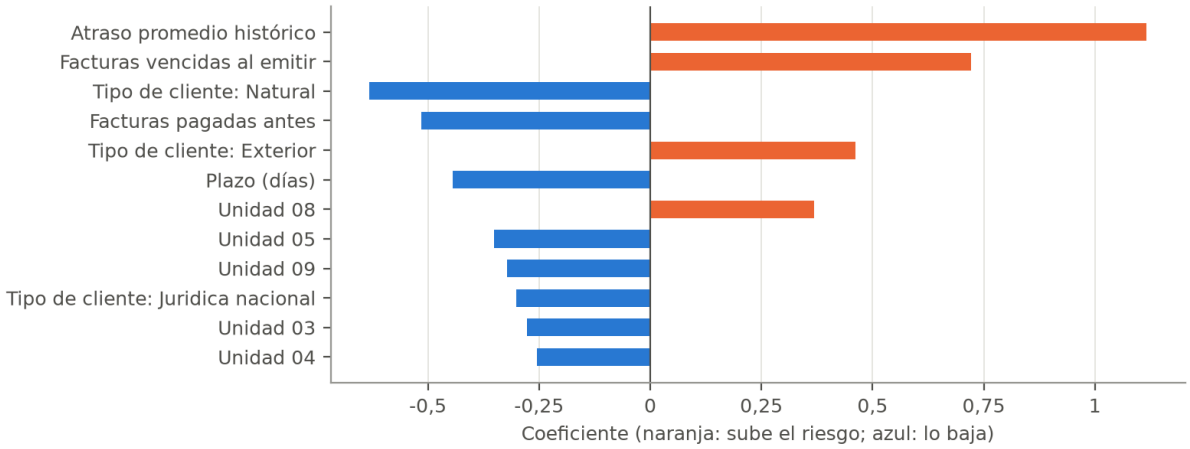


Figura A3. Los 12 coeficientes de mayor magnitud de la logística final, sobre variables escaladas. Indican asociación dentro del modelo, no causa.

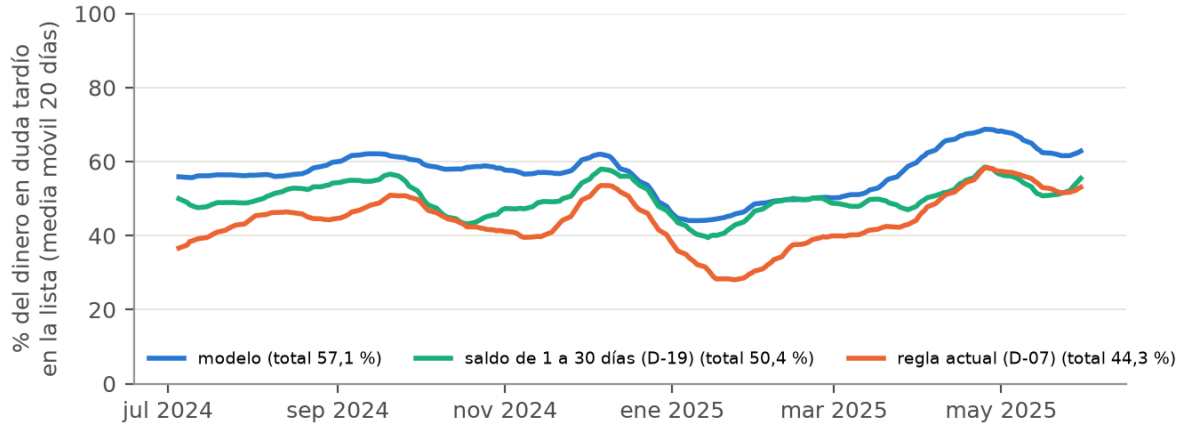


Figura A4. Ensayo del backtest en la validación con K = 20: % del dinero en duda tardío que estaba en cada lista, en media móvil de 20 días hábiles.

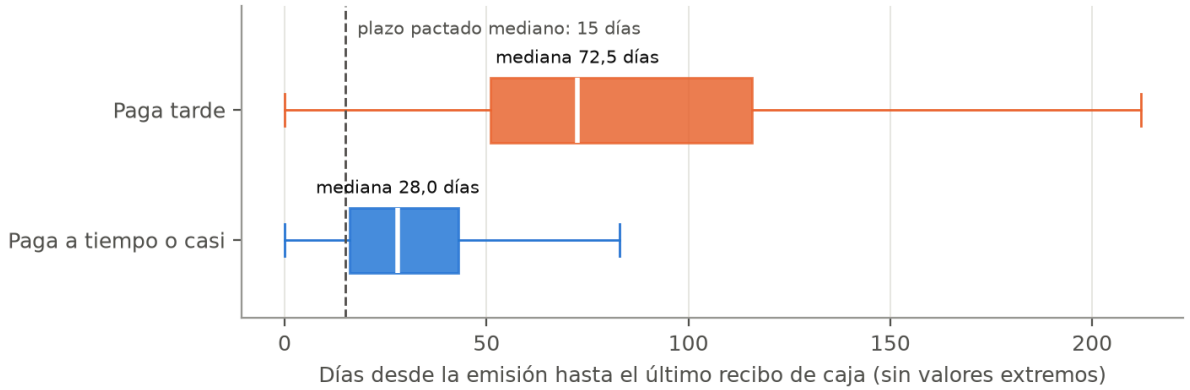


Figura A5. Días desde la emisión hasta el pago por segmento, facturas pagadas antes del 1/07/2025. Cajas: cuartiles; líneas: rango sin valores extremos.

Referencias (APA 7)

Compañía anonimizada. (2026). *Cartera de cuentas por cobrar: saldos y movimientos, 2019–2026* [Datos no publicados, anonimizados; uso autorizado para este proyecto].

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher,

M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.